Einreichung Projektvorschlag

für

Data Analytics

(31.08.26 – 25.09.26)

Projektersteller/Gruppe:

Bosch, Valerij

Daten:

1. **Primär-Datensatz (Historische Basis):**
   - **Datenquelle:** Kaggle (Open Data Repository) – Deutsche Bahn DB Delays Datensatz.
   - **Format & Umfang:** Komprimiertes CSV-Dateiformat (ZIP-Archiv), über 2 Millionen Zeilen. Für den Zugriff ist eine Registrierung auf der Plattform erforderlich.
   - **Lizenzierung:** Open-Source (MIT-Lizenz).
   - Die genaue Konsistenz, Vollständigkeit und Repräsentativität des Datensatzes sind zu Beginn unbekannt.
2. **Sekundärdaten (Optionale API- Erweiterung):**
   - **Quelle:** Entwicklerportal der Deutschen Bahn (DB API Marketplace). (vorgesehene Produkte: „*StaDa* - Station Data“ und „*Timetables*“).
   - **Format:** Strukturierte JSON- und XML-Schnittstellenantworten.
   - **Lizenzierung:** Open Data (Creative Commons Attribution 4.0 International / CC BY 4.0).
   - **Projekt-Integration**: Die Anbindung erfolgt über spezifische Authentifizierungs-Header. Die Beschaffung dieser zusätzlichen Informationen über die APIs wird **rein optional und im Rahmen des verfügbaren Projekt-Zeitbudgets** gestaltet. Die Services dienen als potenzielle Referenzdatenbasis, um den Primärdatensatz bei Bedarf selektiv oder regional (z. B. für ein ausgewähltes Teilnetz wie Bayern) um aktuelle Stammdaten oder Fahrplanstichproben zu ergänzen. Ein vollständiger Abruf oder eine fortlaufende Live-Schnittstelle im Analyse-Notebook sind für den Projekterfolg nicht zwingend erforderlich.
   - Für **APIs-Nutzung** sind Registrierung, sowie *Client-ID* und *API-Key* für Header notwendig.

Projektidee, Beschreibung:

Thema: Explorative Datenanalyse und qualitative Evaluierung eines einwöchigen Schienen-Verspätungsdatensatzes mittels selektiver API-Referenzdaten.

Beschreibung:

Das Projekt verfolgt einen ergebnisoffenen und datenkritischen Ansatz. Da von Dritten bereitgestellte historische Datensätze (Kaggle) strukturelle und qualitative Unsicherheiten aufweisen können, steht zu Beginn die Überprüfung der vorliegenden Datenbasis im Vordergrund. Die Kernidee ist es, den historischen Datensatz stichprobenartig gegen offizielle, via API bezogene Bahnhofsstammdaten der Deutschen Bahn zu spiegeln. Erst durch diesen Abgleich soll transparent ermittelt werden, welche Repräsentativität die Daten tatsächlich besitzen.

Darauf aufbauend wird evaluiert, inwieweit die in den Daten enthaltenen Informationen für weiterführende Analysen genutzt werden können. Neben einer klassischen explorativen Datenanalyse (EDA) der Verspätungsminuten steht die Untersuchung von zeitlichen Korrelationen im Fokus. Am Beispiel ausgewählter Knotenpunkte soll untersucht werden, ob sich durch enge zeitliche Abfolgen von Verspätungen potenzielle Anschlussverluste ableiten lassen. Flankierend dazu wird erforscht, ob und in welchem Umfang die eigenständige Beschaffung zusätzlicher Informationen über externe Schnittstellen einen analytischen Mehrwert als ergänzende Datenquelle bietet. Je nach Datenlage und Projektfortschritt wird optional versucht, signifikante Knotenpunkte, Korrelationen im Liniennetz oder kritische Abhängigkeiten analytisch bzw. visuell darzustellen.

Projektschritte, Aufgaben zum Projekt (falls schon vorhanden):

Die Projektschritte sind bewusst phasenorientiert aufgebaut, um eine flexible Einbindung der im Kurs behandelten Big-Data-Frameworks und Analysetechniken zu ermöglichen:

Phase 1: Datenimport und Performance-Benchmark

- Einlesen und Laden des historischen Primärdatensatzes über verschiedene Frameworks (z. B. Pandas, Dask oder PySpark) zur Untersuchung von Laufzeit und Speichereffizienz.
- Experimenteller Performance-Vergleich beim Laden der Daten aus unterschiedlichen Dateiformaten und Kompressionen (z. B. ZIP, BZ2 und dem spaltenorientierten Parquet-Format).

Phase 2: Explorative Datenanalyse (EDA) & Analytische Visualisierung

- Statistische Auswertung der Verspätungsstrukturen zur Identifikation von Mustern, Datenanomalien und Datentypen.
- Fließender Einsatz von Grafiken (z. B. via Matplotlib/Seaborn) als direktes Werkzeug zur Erkennung von Trends und zur Formulierung analytischer Folgefragen.

Phase 3: Bereitstellung von Referenzdaten & Qualitätsabgleich

- Konzeptionierung und Implementierung einer eigenständigen, modularen Skript-Applikation zur selektiven Beschaffung offizieller Referenzdaten über den DB-Marketplace
- Stichprobenartiger Abgleich des historischen Datensatzes mit den gewonnenen Referenzdaten zur qualitativen Überprüfung der zugrundeliegenden Datenbasis.

Phase 4: Optionale Netzwerkbetrachtung & Anschlussanalyse (Fakultativ)

- Untersuchung von zeitlichen Verspätungskorrelationen an ausgewählten Netzknotenpunkten zur Ableitung potenzieller Anschlussrisiken.

- Optionale Erstellung einer Schienenverkehrs-Netzwerkkarte für ein abgegrenztes Teilnetz unter Einbeziehung der über die API ergänzten geografischen Strukturdaten (je nach verbleibendem Projekt-Zeitbudget).